

UNIVERSIDAD EAFIT

Tatiana Gómez Morales ; Isabella Torres Santamaría &
David Pineda González

IA0301: Big data & Bioinformática

Luisa Gómez Ossa

13 de mayo de 2025

Clasificación automática de enfermedades y deficiencias nutricionales en hojas cítricas mediante visión computacional



Fig 1. Árbol de limón por I.Torres (2025).



INTRODUCCIÓN

En la agricultura moderna, especialmente en cultivos de alto valor como los cítricos, el monitoreo del estado sanitario y nutricional de las plantas es clave para la productividad.

Tradicionalmente, esto se hace de forma manual, lo que puede ser subjetivo, demorado y depende de personal capacitado




Fig 2. Cultivo de limón por I.Torres (2025).

Planteamiento del problema

En el cultivo de cítricos, las enfermedades foliares y deficiencias nutricionales generan pérdidas significativas. La detección oportuna es clave, pero suele depender de expertos y ser subjetiva.



Fig 3. Deficiencia de Mg en cítricos, Yara Colombia(2024).



Fig 4. Deficiencia de zinc en cítricos, Yara Colombia(2024).




Objetivo del proyecto

Desarrollar un sistema de clasificación automática de enfermedades y deficiencias nutricionales en hojas de cítricos mediante imágenes y aprendizaje profundo.



Fig 5. Deficiencia de Cobre en cítricos, Yara Colombia(2024).



Solución propuesta

Un modelo de red neuronal
convolucional (CNN) capaz de
identificar 11 clases distintas de
afecciones en hojas cítricas a partir
de fotografías



Fig 6. Hoja de citricos original por I.Torres (2025).




Fig 7. Hoja de citricos Segmentada por I.Torres (2025).

Clases a identificar

1. Citrus\leafminer

Minador de los cítricos (insecto)



2. HLB

HLB(Huanglongbing-bacteria)



3. Fe

Deficiencia de Hierro



4. Mn

Deficiencia de Manganeso



5. Mg

Deficiencia de Magnesio



Fig 8. Hoja de citricos identificadas con deficiencia o enfermedades (1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11).

Clases a identificar

6. N

Deficiencia de Nitrógeno



7. Zn

Deficiencia de Zinc



8. Healthy

Planta Saludable



9. Greasy_spot

Mancha Grasienta



10. Red_scale_sequelae,
Cochinilla roja (insecto)



11. Texas_mite

Araña roja (arácnido-ácaro)



Fig 8. Hoja de citricos identificadas con deficiencia o enfermedades (1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11).

DATASET

- Fuente: Dataset CitrusUAT
https://data.niaid.nih.gov/resources?id=zenodo_8294077&utm
- Estructura: 11 carpetas (una por clase), 100 imágenes por clase
- Clases: Citrus_leafminer, HLB, Fe, Mn, Mg, N, Zn, Healthy, Greasy_spot, Red_scale_sequelae y Texas_mite

```

✓ Procesada: Citrus_leafminer/Citrus_leafminer_001.jpg
✓ Procesada: Citrus_leafminer/Citrus_leafminer_002.jpg
✓ Procesada: Citrus_leafminer/Citrus_leafminer_003.jpg
✓ Procesada: Citrus_leafminer/Citrus_leafminer_004.jpg
✓ Procesada: Citrus_leafminer/Citrus_leafminer_005.jpg
✓ Procesada: Citrus_leafminer/Citrus_leafminer_006.jpg
✓ Procesada: Citrus_leafminer/Citrus_leafminer_007.jpg
✓ Procesada: Citrus_leafminer/Citrus_leafminer_008.jpg
✓ Procesada: Citrus_leafminer/Citrus_leafminer_009.jpg
✓ Procesada: Citrus_leafminer/Citrus_leafminer_010.jpg
✓ Procesada: Citrus_leafminer/Citrus_leafminer_011.jpg
✓ Procesada: Citrus_leafminer/Citrus_leafminer_012.jpg
✓ Procesada: Citrus_leafminer/Citrus_leafminer_013.jpg
✓ Procesada: Citrus_leafminer/Citrus_leafminer_014.jpg
✓ Procesada: Citrus_leafminer/Citrus_leafminer_015.jpg
✓ Procesada: Citrus_leafminer/Citrus_leafminer_016.jpg
✓ Procesada: Citrus_leafminer/Citrus_leafminer_017.jpg
✓ Procesada: Citrus_leafminer/Citrus_leafminer_018.jpg
✓ Procesada: Citrus_leafminer/Citrus_leafminer_019.jpg
✓ Procesada: Citrus_leafminer/Citrus_leafminer_020.jpg
✓ Procesada: Citrus_leafminer/Citrus_leafminer_021.jpg
✓ Procesada: Citrus_leafminer/Citrus_leafminer_022.jpg
✓ Procesada: Citrus_leafminer/Citrus_leafminer_023.jpg
✓ Procesada: Citrus_leafminer/Citrus_leafminer_024.jpg
✓ Procesada: Citrus_leafminer/Citrus_leafminer_025.jpg
...
✓ Procesada: Zn/Zn_097.jpg
✓ Procesada: Zn/Zn_098.jpg
✓ Procesada: Zn/Zn_099.jpg
✓ Procesada: Zn/Zn_100.jpg

```

Fig 9. Imágenes procesada.

METODOLOGÍA

Nuestra metodología se divide en cinco etapas:

1. Primero, el dataset fue organizado por clases.












Nombre	Estado	Fecha de modificación	Tipo	Tamaño
 Citrus_leafminer	✓	11/05/2025 7:32 p.m.	Carpeta de archivos	
 Fe	✓	11/05/2025 7:32 p.m.	Carpeta de archivos	
 Greasy_spot	✓	11/05/2025 7:32 p.m.	Carpeta de archivos	
 Healthy	✓	11/05/2025 7:32 p.m.	Carpeta de archivos	
 HLB	✓	10/05/2025 12:55 p.m.	Carpeta de archivos	
 Mg	✓	11/05/2025 7:32 p.m.	Carpeta de archivos	
 Mn	✓	10/05/2025 12:55 p.m.	Carpeta de archivos	
 N	✓	10/05/2025 12:56 p.m.	Carpeta de archivos	
 Red_scale_sequelae	✓	11/05/2025 7:32 p.m.	Carpeta de archivos	
 Texas_mite	✓	11/05/2025 7:32 p.m.	Carpeta de archivos	
 Zn	✓	11/05/2025 7:32 p.m.	Carpeta de archivos	

Fig 10. Carpetas con las imágenes de cada deficiencia o enfermedad.




2. Luego, se aplicó una segmentación automática en HSV para aislar la hoja del fondo.

- Generación de máscaras multiclase: 0 = fondo, 1 = hoja, 2 = enfermedad

Imagen original



Canal H (Hue)



Máscara segmentada (hoja)



Fig 11. Imágenes de aplicación de segmentación.



3. Se cálculo del porcentaje de enfermedad por imagen

✓ 59.3s

	Clase	Imagen	Área total hoja (px)	\
0	Citrus_leafminer	Citrus_leafminer_001_mask.png	2703563	
1	Citrus_leafminer	Citrus_leafminer_002_mask.png	2642439	
2	Citrus_leafminer	Citrus_leafminer_003_mask.png	1989957	
3	Citrus_leafminer	Citrus_leafminer_004_mask.png	1956027	
4	Citrus_leafminer	Citrus_leafminer_005_mask.png	1502441	
	Área enferma (px)	Porcentaje de enfermedad (%)		
0	117300	4.34		
1	354130	13.40		
2	25046	1.26		
3	296322	15.15		
4	9298	0.62		

✓ Resultados exportados a: C:/Users/Isabe/OneDrive/Escritorio/Proyecto_Fenotipado/porcentajes_enfermedad.csv

Fig 12. información de las imágenes.



4. División del dataset en entrenamiento y validación

```
✓ Clase 'Citrus_leafminer': 80 train / 20 val
✓ Clase 'Fe': 80 train / 20 val
✓ Clase 'Greasy_spot': 80 train / 20 val
✓ Clase 'Healthy': 80 train / 20 val
✓ Clase 'HLB': 40 train / 10 val
✓ Clase 'Mg': 80 train / 20 val
✓ Clase 'Mn': 40 train / 10 val
✓ Clase 'N': 40 train / 10 val
✓ Clase 'Red_scale_sequelae': 104 train / 26 val
✓ Clase 'Texas_mite': 80 train / 20 val
✓ Clase 'Zn': 80 train / 20 val
🚀 División completa. Listo para entrenamiento.
```

Fig 13. División de entrenamiento.



5. Entrenamiento del modelo CNN para clasificación



```
c:\Users\Isabe\anaconda3\envs\fenotipado-cnn\lib\site-packages\keras\src\layers\convolutional\base_conv.py:107: UserWarning:
    super().__init__(activity_regularizer=activity_regularizer, **kwargs)
c:\Users\Isabe\anaconda3\envs\fenotipado-cnn\lib\site-packages\keras\src\trainers\data_adapters\py_dataset_adapter.py:1
    self._warn_if_super_not_called()
Epoch 1/30
49/49 ————— 58s 1s/step - accuracy: 0.0805 - loss: 2.8169 - val_accuracy: 0.1735 - val_loss: 2.2690
Epoch 2/30
49/49 ————— 51s 1s/step - accuracy: 0.2210 - loss: 2.2342 - val_accuracy: 0.3469 - val_loss: 2.0035
Epoch 3/30
49/49 ————— 61s 1s/step - accuracy: 0.3074 - loss: 1.9924 - val_accuracy: 0.4439 - val_loss: 1.5564
Epoch 4/30
49/49 ————— 62s 1s/step - accuracy: 0.4128 - loss: 1.6030 - val_accuracy: 0.5357 - val_loss: 1.3642
Epoch 5/30
49/49 ————— 63s 1s/step - accuracy: 0.5073 - loss: 1.3823 - val_accuracy: 0.5204 - val_loss: 1.3425
Epoch 6/30
49/49 ————— 59s 1s/step - accuracy: 0.5666 - loss: 1.2167 - val_accuracy: 0.6633 - val_loss: 0.9813
Epoch 7/30
49/49 ————— 58s 1s/step - accuracy: 0.6327 - loss: 1.0289 - val_accuracy: 0.6633 - val_loss: 1.0207
Epoch 8/30
49/49 ————— 59s 1s/step - accuracy: 0.6591 - loss: 0.9533 - val_accuracy: 0.6888 - val_loss: 0.8801
Epoch 9/30
49/49 ————— 58s 1s/step - accuracy: 0.7043 - loss: 0.8311 - val_accuracy: 0.7755 - val_loss: 0.7523
Epoch 10/30
49/49 ————— 53s 1s/step - accuracy: 0.7845 - loss: 0.6384 - val_accuracy: 0.6888 - val_loss: 0.8577
Epoch 11/30
49/49 ————— 51s 1s/step - accuracy: 0.7603 - loss: 0.7126 - val_accuracy: 0.7245 - val_loss: 0.7759
Epoch 12/30
49/49 ————— 48s 979ms/step - accuracy: 0.8035 - loss: 0.5528 - val_accuracy: 0.7296 - val_loss: 0.7836
...
Epoch 17/30
49/49 ————— 50s 1s/step - accuracy: 0.8784 - loss: 0.3342 - val_accuracy: 0.7857 - val_loss: 0.6043
Epoch 18/30
49/49 ————— 54s 1s/step - accuracy: 0.8873 - loss: 0.3019 - val_accuracy: 0.8316 - val_loss: 0.6077
```

Fig 14. Procesamiento del entrenamiento.

6. Evaluación del modelo – Matriz de confusión y métricas



Fig 15. Correlación - modelo.


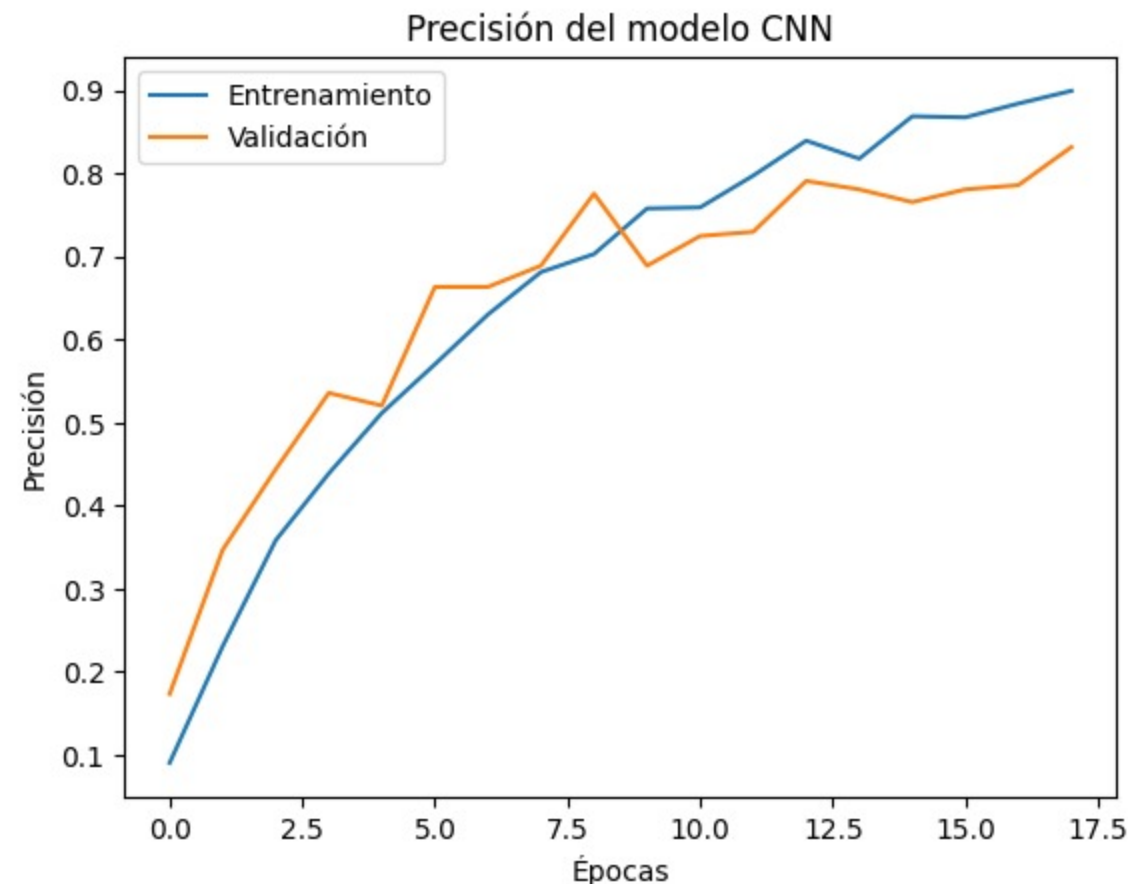


Fig 16. Matriz de confusión.

Resultados

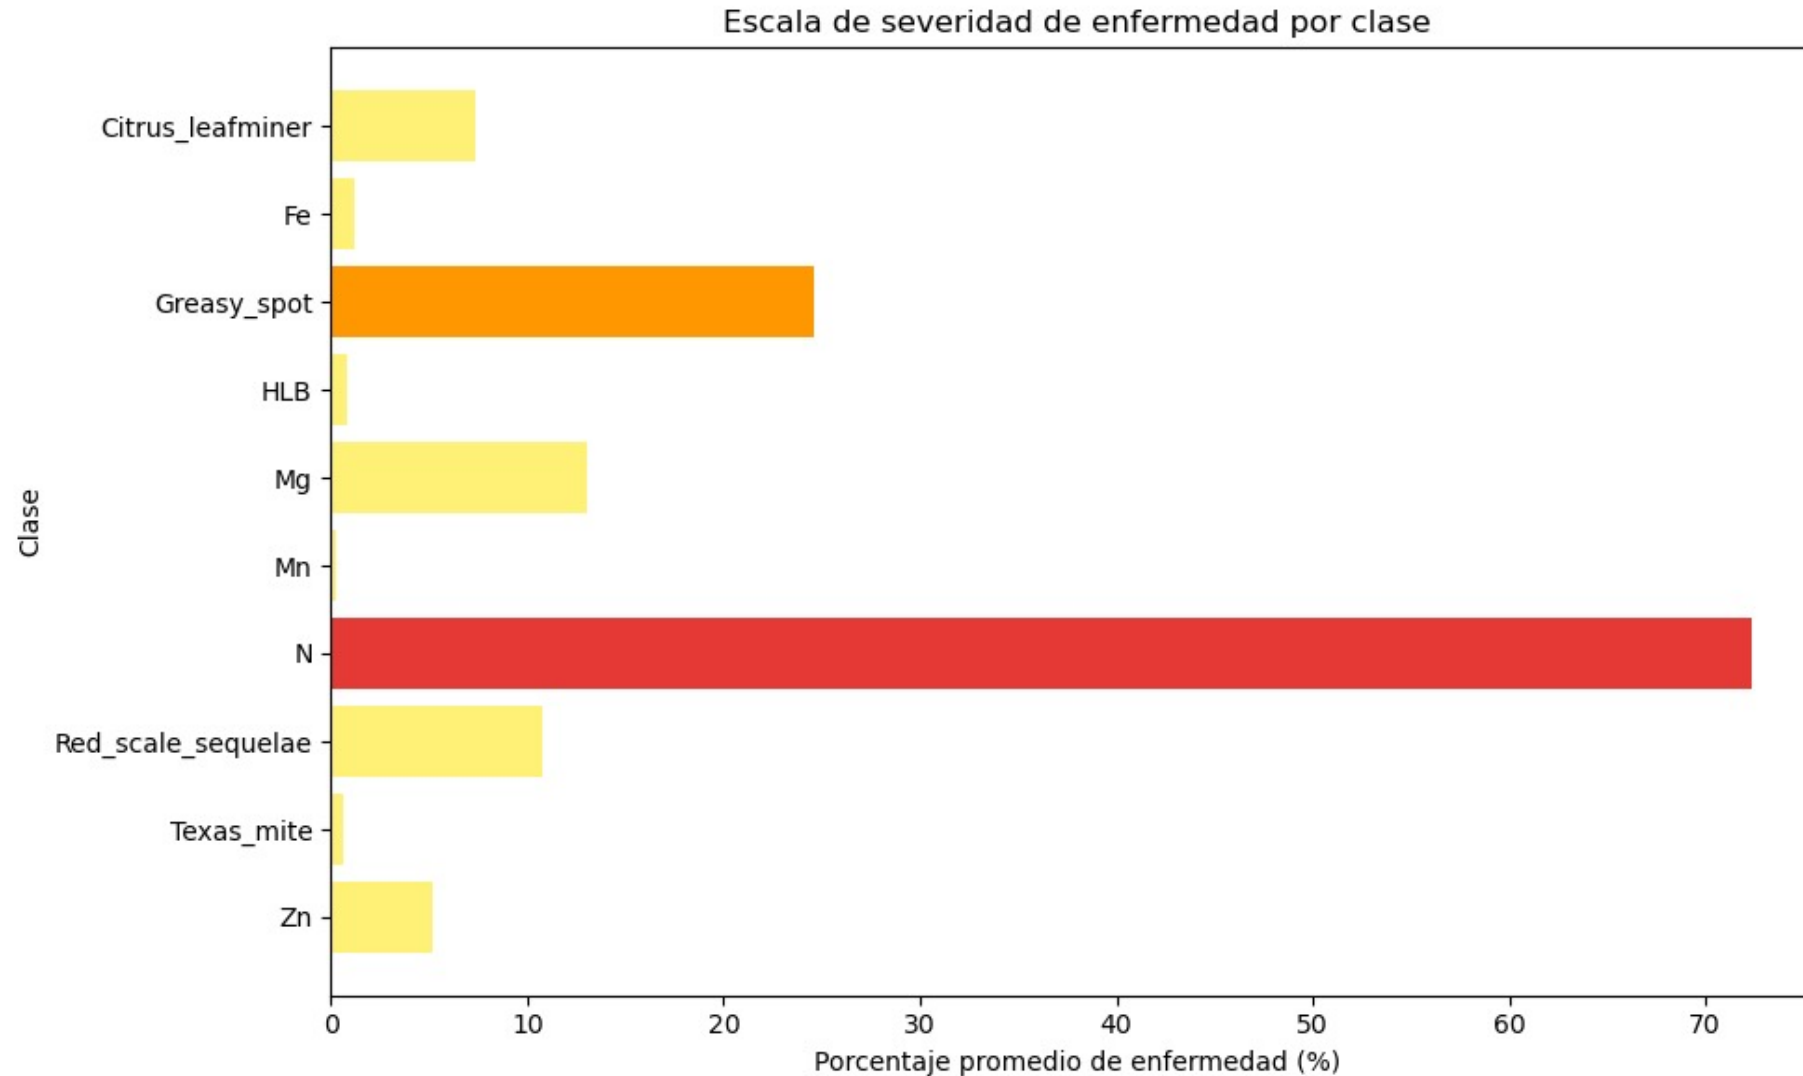
Precisión del modelo (accuracy)

- El modelo alcanzó una precisión de validación de aproximadamente **84%** en la **época 17**, con una curva de entrenamiento ascendente y sin signos evidentes de sobreajuste.
- Se observa un **buen comportamiento general**, con la curva de validación manteniéndose cercana a la de entrenamiento, lo que indica **una buena generalización** del modelo sobre datos no vistos.



Grafica 1. Evaluación de precisión.

Visualización de predicciones



Grafica 2. Severidad de clases.

Resultados

Matriz de confusión

Las clases con mayor precisión fueron:

- **Healthy** (19/20 clasificadas correctamente)
- **Texas_mite** y **Zn deficiency** (18/20 correctas)
- **Fe deficiency** (19/20 correctas)

Las clases con mayor confusión fueron:

- **Citrus leafminer**, confundida ocasionalmente con Red_scale_sequelae y Zn
- **HLB** confundida con Healthy
- **Red_scale_sequelae** confundida con Citrus leafminer y N deficiency




Fig 17. Matriz de confusión.

Resultados

Predicción de enfermedades o deficiencias.




Fig 17. Hoja identificada Fe.

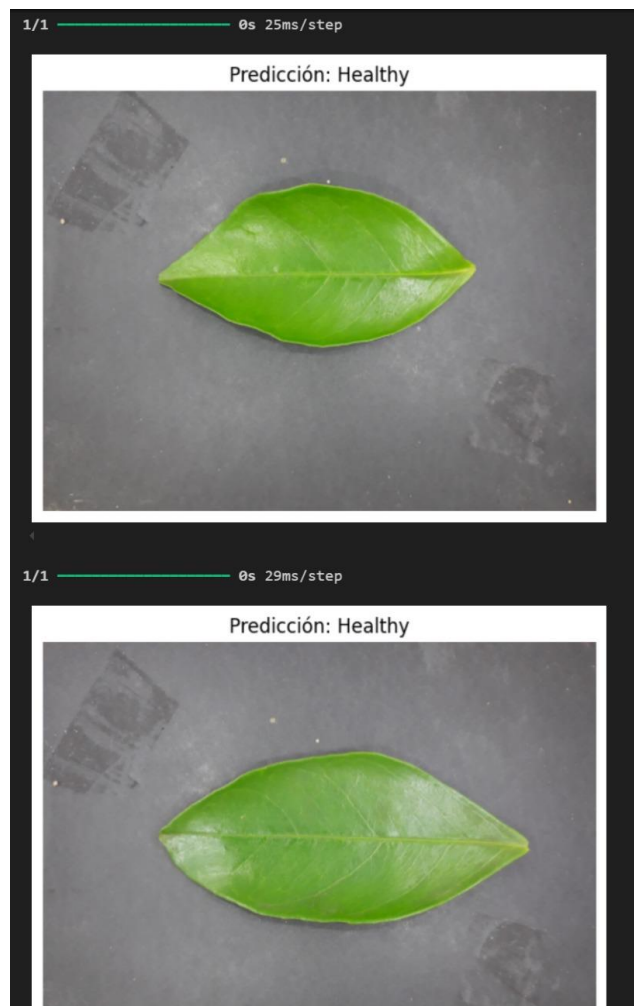


Fig 18. Hoja identificada como sana.

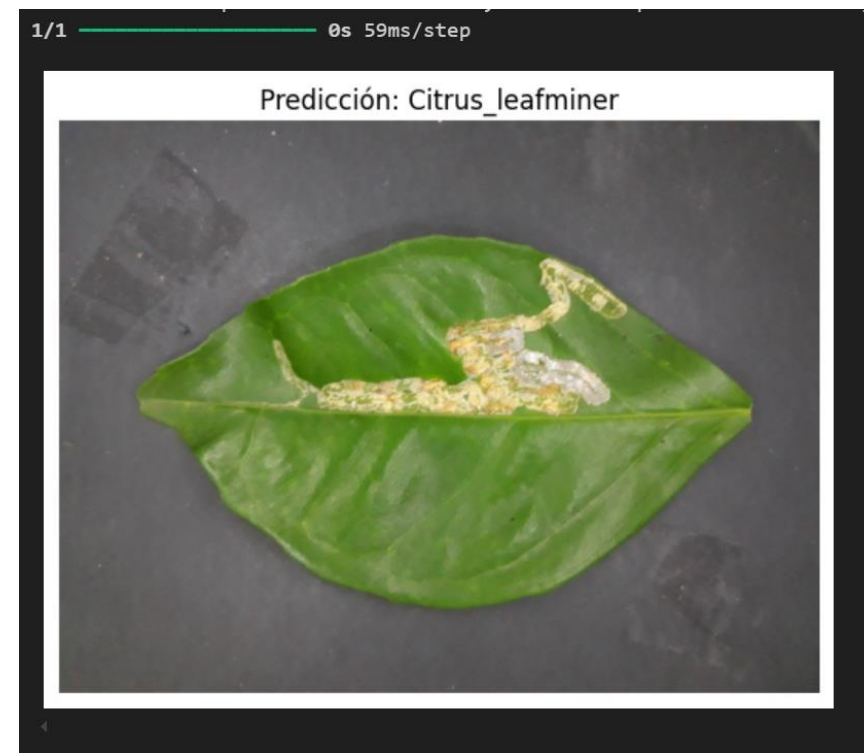


Fig 19. Hoja identificada Citrus_leafminer.

¿Para qué sirve?

1. Asistente de diagnóstico en campo
2. Reducción de dependencia de expertos
3. Agiliza la toma de decisiones
4. Escalable a más cultivos en el futuro



Fig 19. Foto simulada en Campo.

CONCLUSIONES



El modelo CNN alcanzó un 84 % de precisión en clasificación, sin sobreentrenamiento



Se distinguieron 11 clases de hojas con fenotipado vegetal automatizado



Las clases más confundidas fueron HLB-Hoja sana y Leafminer-Red Scale



El flujo de trabajo es aplicable en agricultura de precisión

Fig 20. Concluciones.

REFERENCIAS

1. Emon, Y. R., Rabbani, M. G., Ahad, M. T., & Ahmed, F. (2023). A Comprehensive Literature Review on Sweet Orange Leaf Diseases. arXiv preprint arXiv:2312.01756.
2. Manso, G. L., Knidel, H., Krohling, R. A., & Ventura, J. A. (2019). A smartphone application to detection and classification of coffee leaf miner and coffee leaf rust. arXiv preprint arXiv:1904.00742.
3. Plant disease epidemiology. (2025). Wikipedia.
https://en.wikipedia.org/wiki/Plant_disease_epidemiology
4. Alkay, I., & Akdeniz University. (2020). Citrus Leaves Dataset (CitrusUAT) [Imagen]. GitHub.
<https://github.com/ialkay/Citrus-Leaves-Dataset>